

# Анализ свойств процедуры выравнивания временных рядов в задачах метрической классификации

Александра Харь

Московский физико-технический институт  
Факультет управления и прикладной математики  
Кафедра интеллектуальных систем

Консультанты: Г. Моргачев, А. Гончаров  
Научный руководитель д.ф.-м.н. В. В. Стрижов

## Цель работы

Обосновать применение DTW для метрических методов классификации временных рядов.

## Метод анализа

Сравнение качества классификации временных рядов (при помощи SVM) с использованием динамического выравнивания (DTW) и без него. В процессе эксперимента в качестве ядра в SVM используются следующие матрицы: матрица попарных расстояний между временными рядами, полученная при помощи DTW, некоторые ее модификации, а также матрица попарных Евклидовых расстояний между временными рядами.

- Hui Ding, Goce Trajcevski, Peter Scheuermann, Xiaoyue Wang, and Eamonn J. Keogh. Querying and mining of time series data: experimental comparison of representations and distance measures. PVLDB, 1(2):1542–1552, 2008.
- Chan P. Fastdtw Salvador S. Toward accurate dynamic time warping in linear time and space. In Workshop on Mining Temporal and Sequential Data, page 11, 2004.
- Kristin P. Bennett and Colin Campbell. Support vector machines: Hype or hallelujah? SIGKDD Explorations, 2(2):1–13, 2000.

Объекты  $\mathbf{x} \in \mathbb{R}^n$  – временные ряды, принадлежащие двум непересекающимся классам  $Y = \{+1, -1\}$

Линейный классификатор:  $a(\mathbf{x}) = \text{sign}(\langle \mathbf{w}, \mathbf{x} \rangle - w_0)$ , где

$\mathbf{x} = [x_1, \dots, x_n]^T$  – признаковое описание объекта  $x$ ,

$\mathbf{w} = [w_1, \dots, w_n]^T \in \mathbb{R}^n$  и  $w_0 \in \mathbb{R}$  – веса признаков



$\langle \mathbf{w}, \mathbf{x} \rangle = w_0$  – гиперплоскость, разделяющая классы

задача оптимизации: 
$$\begin{cases} \frac{1}{2} \langle \mathbf{w}, \mathbf{w} \rangle \rightarrow \min \\ (\langle \mathbf{w}, \mathbf{x}_j \rangle - w_0) y_j \geq 1; \quad i = 1, \dots, \ell. \end{cases}$$

# Теоретическая часть: динамическое выравнивание

Метод динамического выравнивания – DTW используется для определения сходства между двумя временными рядами и введения расстояния между ними. Он находит наилучшее соответствие между двумя временными рядами, если они нелинейно деформированы друг относительно друга – растянуты, сжаты или смещены вдоль оси времени.

Примеры работы DTW (построение выравнивающего пути):



Рассмотрим два временных ряда  $Q$  и  $C$  разной длины:

$$Q = q_1, q_2, \dots, q_i, \dots, q_n; \quad C = c_1, c_2, \dots, c_j, \dots, c_m$$

- 1 строим матрицу  $d$  размера  $n \times m$ , в которой элемент  $d_{ij} = (q_i - c_j)^2$  – расстояние между двумя точками  $q_i$  и  $c_j$
- 2 строим матрицу трансформации  $D$ , каждый элемент которой вычисляется следующим образом:

$$D_{ij} = d_{ij} + \min(D_{i-1, j}, D_{i-1, j-1}, D_{i, j-1})$$

- 3 строим путь трансформации  $W$  – минимизирует общее расстояние между  $Q$  и  $C$

$$W = w_1, w_2, \dots, w_k, \dots, w_K, \text{ где} \\ w_k = (i, j)_k, \quad d(w_k) = (q_i - c_j)^2$$

- 4  $\rho_{DTW}(Q, C) = \min \left\{ \sum_{k=1}^K d(w_k) / K \right\}$

Если выборка не является линейно разделимой, то для классификации при помощи SVM необходимо перейти в пространство большей размерности, где она уже будет линейно разделима. Скалярное произведение  $\langle \mathbf{x}, \mathbf{x}' \rangle$ , таким образом, везде заменяется на значение функции ядра в соответствующих двух точках  $K(\mathbf{x}, \mathbf{x}')$ .

## Теорема Мерсера:

Функция  $K(\mathbf{x}, \mathbf{x}')$  является ядром тогда и только тогда, когда:

- $K(\mathbf{x}, \mathbf{x}') = K(\mathbf{x}', \mathbf{x})$
- матрица  $K = [K(\mathbf{x}_i, \mathbf{x}_j)]_{i,j}$  неотрицательно определена:  
 $\mathbf{v}^T K \mathbf{v} \geq 0, \quad \forall \mathbf{v} \in \mathbb{R}^n.$

При помощи алгоритма DTW вычисляется попарное расстояние между временными рядами, эти расстояния записываются в матрицу  $D$ . В таком случае она будет симметричной, с нулями на диагонали. При помощи теоремы Мерсера выявляется, что  $D$  не является ядром (не является неотрицательно определенной). Так как для перехода в пространство большей размерности в алгоритме SVM для более качественной классификации обычно используют ядро, то мы попробуем модифицировать  $D$ , чтобы она стала таковым, затем сравним точности классификации при использовании первоначальной  $D$  и модифицированных матриц.




## Модифицируем $D$ двумя способами:


- Ищем ближайшую к матрице  $D$  неотрицательно определенную матрицу  $A$  следующим образом:  
так как  $D$  – симметрична, то  $D = QMQ^T$ , где  $M$  – диагональная с собственными числами  $D$  на диагонали  
 $M_+ = [\max(M_{ij}, 0)]_{ij}$   
 $A = QM_+Q^T$  – неотрицательно определенная
- Создаем RBF-ядро  $K(x, x') = \exp(-\gamma \cdot \rho_{dtw}(x, x'))$ , где  $\rho_{dtw}(x, x')$  – расстояние между рядами  $x$  и  $x'$ .  
Получаем матрицу  $Z$ , она уже является ядром, что было проверено на эксперименте при помощи теоремы Мерсера.

На небольшом объеме данных матрицы выглядят следующим образом:


## Матрица D



## Матрица A



## Матрица Z



Используем эти матрицы, а также обыкновенную норму  $l_2$  в качестве ядра в алгоритме SVM для классификации данных и оцениваем точность классификации.

## Оценка точности классификации

- метрика  $l_2$  : 0.182
- матрица  $D$  : 0.327
- матрица  $A$  : 0.523
- матрица  $Z$  : 0.864

Метрика  $l_2$  дает худший результат, следующая по качеству – матрица  $D$  попарных расстояний между рядами, а затем уже две ее модификации – матрицы  $A$  и  $Z$ , причем при помощи RBF-ядра  $Z$  получена лучшая классификация.

- Произведена классификация временных рядов при помощи яdroвого SVM с различными ядрами: метрика  $l_2$ , матрица расстояния между временными рядами  $D$ , ее аппроксимация до ядра  $A$ , и RBF ядро  $Z$ .
- Проведено сравнение данных классификаций.
- Использование матрицы  $D$  попарных расстояний улучшает точность классификации по сравнению с  $l_2$  на 15%.
- Модифицированные версии  $A$  и  $Z$  матрицы  $D$  улучшают точность классификации еще на 20 и 55 % соответственно.